

**INSTITUTO FEDERAL DO PARANÁ**  
**CAMPUS PINHAIS**  
**CURSO TÉCNICO EM INFORMÁTICA INTEGRADO AO ENSINO MÉDIO**

**MURILO HENRIQUE DA SILVA COMANDULLI**  
**PEDRO GABRIEL DOS SANTOS SOUZA**  
**RICARDO DA SILVA LACERDA**

**LUMOR AI: APRENDIZADO DE MÁQUINA E ANÁLISE COMPUTACIONAL DE  
IMAGENS MÉDICAS PARA CLASSIFICAÇÃO DE TUMORES CEREBRAIS**

**MURILO HENRIQUE DA SILVA COMANDULLI**  
**PEDRO GABRIEL DOS SANTOS SOUZA**  
**RICARDO DA SILVA LACERDA**

**LUMOR AI: APRENDIZADO DE MÁQUINA E ANÁLISE COMPUTACIONAL DE  
IMAGENS MÉDICAS PARA CLASSIFICAÇÃO DE TUMORES CEREBRAIS**

Trabalho apresentado ao Curso Técnico em Informática Integrado ao Ensino Médio do Campus Pinhais, do Instituto Federal do Paraná, como requisito parcial para aprovação nos componentes curriculares Trabalho de Conclusão de Curso e Orientação TCC.

Professores Responsáveis:  
Prof. Dr. Eduardo Tieppo.  
Prof. Me. Izaque Esteves da Silva

**PINHAIS**

**2026**

## **1 DELIMITAÇÃO DO TEMA**

O projeto se delimita na área de desenvolvimento e avaliação de modelos de Aprendizado de Máquina voltados à classificação binária de tumores cerebrais em imagens médicas de Tomografia Computadorizada (TC) e Ressonância Magnética (RM). A pesquisa se especifica entre as áreas de Inteligência Artificial, processamento de imagens médicas e saúde.

A pesquisa será realizada no espaço do Instituto Federal do Paraná, Campus Pinhais, com uso de bases de dados públicas disponibilizadas na plataforma Kaggle. O período de execução compreende o ano de 2026, no âmbito do componente curricular Trabalho de Conclusão de Curso. A população envolvida é indireta: os dados utilizados são imagens clínicas anonimizadas de pacientes com e sem diagnóstico de tumores cerebrais.

## 2 JUSTIFICATIVA

Tumores cerebrais, embora tenham baixa incidência, algo próximo de cinco a sete casos a cada cem mil pessoas, apresentam taxa de mortalidade extremamente elevada, chegando a 67% dos casos. Seu diagnóstico depende de exames de imagem como TC e RM, exigindo profissionais qualificados para sua interpretação. Em regiões de maior vulnerabilidade socioeconômica, a escassez de especialistas e de equipamentos adequados representa uma barreira crítica para se adquirir um prognóstico, o que pode resultar em sequelas graves ou óbito em casos mais críticos.

Nesse contexto, ferramentas de Inteligência Artificial baseadas em Aprendizado de Máquina supervisionado apresentam grande potencial para auxiliar no processo diagnóstico, agilizando a identificação de anomalias e reduzindo a sobrecarga de médicos especializados. A criação do Lumor AI justifica-se nessa necessidade de investigar a aplicabilidade de modelos de classificação em imagens médicas, contribuindo para o avanço de soluções tecnológicas voltadas à saúde.

### 3 PROBLEMA DE PESQUISA

Quais modelos de Aprendizado de Máquina, combinados a técnicas de extração de características, apresentam maior *accuracy*, *precision*, *recall* e *F1-score* na classificação binária de tumores cerebrais em imagens de TC e RM?

## 4 OBJETIVOS

### 4.1 Objetivo Geral

Avaliar e comparar modelos de Inteligência Artificial capazes de identificar, em imagens de Tomografia Computadorizada ou Ressonância Magnética, a presença ou ausência de tumores cerebrais, utilizando como base conjuntos de dados públicos e documentações científicas.

### 4.2 Objetivos Específicos

- Adquirir bases de dados públicas com imagens de TC e RM de pacientes com e sem tumores cerebrais;
- Aplicar técnicas de extração de características sobre as imagens coletadas para geração de vetores de atributos;
- Criar e treinar modelos de classificação binária utilizando os vetores extraídos;
- Estudar as técnicas de extração de características, modelos de inteligência artificial, e métodos de validação;
- Avaliar e comparar os modelos por meio de métricas como *accuracy*, *precision*, *recall* e *F1-score*, utilizando validação cruzada;
- Selecionar o modelo com melhor desempenho e utilizá-lo em análises experimentais por meio do software Lumor AI.

## 5 METODOLOGIA

A pesquisa tem caráter analítico-experimental, com abordagem de aprendizado supervisionado. O estudo parte da coleta de bases de dados públicas na plataforma Kaggle, usando os datasets BrainTumor\_CT\_scan Images e Brain Tumor DataSet, contendo imagens de TC e RM com e sem presença de tumor, que são modificadas por meio de técnicas de aumento de dados, como rotações e inversões, , mas sem alterar suas características principais, visando maior capacidade de generalização dos modelos.

As imagens são rotuladas em duas classes genéricas: "Tumor" e "Healthy". A extração de características é realizada pelos métodos Haralick e Local Binary Patterns (LBP), selecionados após análise prévia onde foi comparado com outros métodos por apresentarem resultados superiores na tarefa de classificação. Os vetores de características gerados são utilizados no treinamento dos classificadores KNN, SVM, Naive Bayes, Random Forest, com otimização de hiperparâmetros via grid search.

A avaliação dos modelos é feita por meio do protocolo k-fold cross-validation, com as métricas *accuracy*, *precision*, *recall* e *F1-score*, complementadas pela análise de matrizes de confusão. O modelo com melhor desempenho é integrado ao software Lumor AI, desenvolvido como ferramenta para a condução das análises experimentais, permitindo carregar imagens de TC ou RM e obter a predição do modelo. A etapa de validação estatística complementa a análise comparativa entre os classificadores avaliados.



## 6 REVISÃO DA LITERATURA

O Aprendizado de Máquina (AM) é uma subárea da Inteligência Artificial composta por algoritmos capazes de identificar padrões em dados e realizar previsões sobre novos exemplares. O Deep Learning, subárea do AM, utiliza redes neurais artificiais e domina os resultados de ponta em tarefas de reconhecimento de imagens (Dave Bergmann, 2025; Bishop, 2006).

A classificação é uma tarefa do AM que associa dados de entrada, previamente rotulados, a categorias pré-definidas. Na classificação binária, os dados são associados a uma de duas classes possíveis, como "Tumor" e "Healthy", enquanto que na classificação multiclasse há mais de duas possibilidades (Kotsiantis, 2007; Murel; Kavlakoglu, 2024).

Dentre os métodos de extração de características aplicados a imagens médicas, destacam-se o Haralick, que captura propriedades texturais por meio de matrizes de co-ocorrência de tons de cinza, e o LBP (Local Binary Patterns), que codifica padrões locais de textura de forma robusta a variações de iluminação. Ambos geram vetores de características que são utilizados no treinamento dos modelos (Goceri, 2023).

Para avaliação dos modelos, a literatura recomenda o uso combinado de métricas como *accuracy*, *precision*, *recall* e *F1-score*, derivadas da matriz de confusão (Sokolova; Japkowicz; Szpakowicz, 2006). O protocolo k-fold cross-validation garante a estimativa confiável da capacidade de generalização dos modelos (Raschka, 2020). A otimização de hiperparâmetros por grid search é prática consolidada para maximizar o desempenho de classificadores como KNN, SVM e Random Forest (Probst; Wright; Boulesteix, 2019).





## 8 REFERÊNCIAS

AMARO JÚNIOR, Edson; YAMASHITA, Helio. Aspectos básicos de tomografia computadorizada e ressonância magnética. *Revista Brasileira de Psiquiatria*, v. 23, n. suppl 1, p. 2–3, maio 2001.

BISHOP, Christopher. *Pattern Recognition and Machine Learning*. Nova York: Springer, 2006.

DAVE BERGMANN. What is Machine Learning? IBM. Disponível em: <<https://www.ibm.com/think/topics/machine-learning>>. Acesso em: 3 mar. 2026.

GOCERI, Evgin. Medical image data augmentation: techniques, comparisons and interpretations. *Artificial Intelligence Review*, v. 56, n. 11, p. 12561–12605, nov. 2023.

KOTSIANTIS, S. B. *Emerging Artificial Intelligence Applications in Computer Engineering*. IOS Press, 2007.

MUREL, Jacob; KAVLAKOGLU, Eda. What are classification models? IBM. Disponível em: <<https://www.ibm.com/think/topics/classification-models>>. Acesso em: 10 mar. 2026.

PROBST, Philipp; WRIGHT, Marvin; BOULESTEIX, Anne-Laure. Hyperparameters and Tuning Strategies for Random Forest. *WIREs Data Mining and Knowledge Discovery*, v. 9, n. 3, p. e1301, maio 2019.

RASCHKA, Sebastian. *Model Evaluation, Model Selection, and Algorithm Selection in Machine Learning*. arXiv, 11 nov. 2020.

SOKOLOVA, Marina; JAPKOWICZ, Nathalie; SZPAKOWICZ, Stan. Beyond Accuracy, F-Score and ROC: A Family of Discriminant Measures for Performance Evaluation. In: *AI 2006: Advances in Artificial Intelligence*. Berlin: Springer, 2006. p. 1015–1021.